Οικονομικό Πανεπιστήμιο Αθηνών

Τμήμα Στατιστικής

Μεθοδολογικά Εργαλεία της Μηχανικής Μάθησης
Το φαινόμενο του Double Descent

Πέτρος Χριστοδούλου
s6210114
Διδάσκοντες : Α. Γιαννακόπουλος , Στ. Βακερούδης
13 Ιανουαρίου 2026

Περίληψη

Για δεκαετίες η Κλασική Προσέγγιση της μηχανικής μάθησης ισχυριζόταν πως στην προσπάθειά μας να συμβιβαστούμε μεταξύ της σχέσης μεροληψίας και διακύμανσης, καταλήγαμε σε ένα σημείο από το οποίο και μετά η αύξηση των παραμέτρων, ενώ αρχικά βελτιώνει την απόδοση, οδηγεί τελικά σε αύξηση του σφάλματος γενίκευσης λόγω Υπερ-προσαρμογής. Ωστόσο το δόγμα αυτό καταρρίφθηκε όταν βρέθηκε πως με συνεχή προσθήκη παραμέτρων όταν φτάναμε στο κατώφλι παρεμβολής, στο σημείο δηλαδή οπού ο αριθμός των παραμέτρων ήταν ίσος με το μέγεθος του δείγματος, ακολουθούσε μια μείωση του σφάλματος η οποία οδηγούσε ξανά σε βελτίωση της επίδοσης, πολλές φορές σε επιδόσεις καλύτερες ακόμη και από ότι προηγουμένως.

Περιεχόμενα

1 Εισαγωγή **1**

1.1 Τι είναι Μηχανική Μάθηση; 1

1.2 Κλασική Προσέγγιση 1

1.3 Το Φαινόμενο της Διπλής Καθόδου (Double Descent) 1

1.3.1 Γιατί η Υπερ-παραμετροποίηση Βελτιώνει τη Γενίκευση; 2

1.3.2 Ο Ρόλος του Χρόνου Εκπαίδευσης στην Διπλή Κάθοδο 2

1.3.3 Ο Ρόλος του Δείγματος Εκπαίδευσης στην Διπλή Κάθοδο 2

2 Παρουσίαση του Φαινομένου της Διπλής Καθόδου **3**

2.1 Δεδομένα 3

2.2 Μεθοδολογία 3

2.2.1 Προσομοιωμένα Δεδομένα 3

2.2.2 Πραγματικά Δεδομένα (Heart Disease) 3

3 Αποτελέσματα **4**

3.1 Προσομοιωμένα Δεδομένα 4

3.2 Πραγματικά Δεδομένα (Heart Disease) 5

3.3 Διαφορές Μεταξύ των Διαγραμμάτων 6

4 Συμπεράσματα **7**

1 Εισαγωγή

1.1 Τι είναι Μηχανική Μάθηση;

Μηχανική μάθηση είναι ένας κλάδος της τεχνητής νοημοσύνης κατά τον οποίο ένας αλγόριθμος υλοποιεί υπολογιστικές διαδικασίες προκειμένου να πετύχει ένα αποτέλεσμα χωρίς όμως να έχει προγραμματιστεί ρητά για την επίτευξη του αποτελέσματος αυτού [2]. Κατά την δημιουργία του αλγορίθμου τα δεδομένα χωρίζονται σε δύο υποσύνολα, το σύνολο της εκπαίδευσης και το σύνολο ελέγχου. Σκοπός του διαχωρισμού είναι ο έλεγχος της απόδοσης του μοντέλου δηλαδή πόσο καλά μπορεί να γενικευτεί σε καινούργια δεδομένα. Πως αποφασίζεται όμως το μέγεθος των υποσυνόλων;

1.2 Κλασική Προσέγγιση

Η λογική που ακολουθούσε η Κλασική Προσέγγιση προσπαθούσε να βρει μια ισορροπία μεταξύ της διακύμανσης και της μεροληψίας του μοντέλου. Η ισορροπία βασιζόταν καθαρά στην πολυπλοκότητα του μοντέλου. Η πολυπλοκότητα μπορεί να χαρακτηριστεί ως συνάρτηση της σχέσης του μεγέθους του δείγματος με του αριθμού παραμέτρων που έχουμε[3]. Η κλασική προσέγγιση θεωρούσε πως αν ένα μοντέλο είχε μεγάλη πολυπλοκότητα η ικανότητα γενίκευσης του ήταν αδύναμη. Συγκεκριμένα έστω ότι έχουμε ένα σταθερό αριθμό παραμέτρων d. Ένα συγκριτικά μεγάλο σε σχέση με το d σύνολο εκπαίδευσης κάνει το μοντέλο πιο δύσκαμπτο. Έτσι κυριαρχεί η μεροληψία. Αντιθέτως, ένα συγκριτικά μικρό σύνολο εκπαίδευσης κάνει το μοντέλο πολύ εύκαμπτο και οδηγεί σε αύξηση της διακύμανσης. Έτσι ορίζεται και η αύξηση της πολυπλοκότητας, με αύξηση του αριθμού των παραμέτρων έναντι των δεδομένων του συνόλου εκπαίδευσης. Οι έννοιες της μεροληψίας και της διακύμανσης είναι αντιστρόφως ανάλογες καθώς με βελτίωση της μίας υπάρχει επιδείνωση της άλλης. Η ιδανική σχέση μεταξύ των δύο βρίσκεται στο σημείο όπου το σφάλμα γενίκευσης ελαχιστοποιείται το οποίο γραφικά αναπαριστάται ως μια καμπύλη σχήματος U και το ιδανικό σημείο είναι στην βάση του (βλέπε Σχήμα 1).

$$EPE_k(x_0) = \sigma^2 + [f(x_0) - \frac{1}{k}\sum_{l=1}^{k} f(x_{(l)})]^2 + \frac{\sigma^2}{k} \tag{1}$$

Η σχέση (1) αποτελεί την μαθηματική Ανάλυση του Σφάλματος Γενίκευσης. Η έκφραση στις αγκύλες αποτελεί την μεροληψία ενώ η τελευταία έκφραση της σχέσης την διακύμανση. Η πολυπλοκότητα αντιπροσωπεύεται από την παράμετρο k. Με αύξηση του k η μεροληψία αυξάνεται ενώ με μείωση αυξάνεται η διακύμανση.

1.3 Το Φαινόμενο της Διπλής Καθόδου (Double Descent)

Την ιδέα ότι η μοναδική ιδανική σχέση βρίσκεται στο σημείο ελαχιστοποίησης του σφάλματος ήρθε να καταρρίψει η ανακάλυψη του φαινομένου της Διπλής Καθόδου. Αναφέρθηκε ότι η αύξηση πολυπλοκότητας επιτυγχάνεται μέσω αύξησης του αριθμού παραμέτρων. Ωστόσο με περαιτέρω αύξηση των παραμέτρων το μοντέλο αναπόφευκτα καταλήγει σε ένα σημείο στο οποίο ο αριθμός των παραμέτρων είναι ίσος με τον αριθμό των δεδομένων. Το σημείο αυτό ονομάζεται Σημείο Παρεμβολής (Interpolation Threshold) και αποτελεί ζωτικό σημείο τόσο για το μοντέλο όσο και για την κατανόηση της Διπλής Καθόδου καθώς στο σημείο αυτό το μοντέλο έχει μηδενικό σφάλμα εκπαίδευσης, μέγιστο σφάλμα γενίκευσης και μέγιστη διακύμανση. Αποδείχθηκε πως, καθώς το μοντέλο αποκτά περισσότερες παραμέτρους από ότι δεδομένα (Υπερ-παραμετροποίηση) και ξεπερνάει το Σημείο Παρεμβολής η απόδοση του μοντέλου συναντά ένα δεύτερο στάδιο βελτίωσης καθώς το σφάλμα γενίκευσης μειώνεται[1]. Το φαινόμενο αρχικά αποδείχθηκε σε μοντέλα όπως γραμμικά μοντέλα με τυχαία χαρακτηριστικά και μεθόδους πυρήνων και στην συνέχεια επεκτάθηκε και στα βαθιά νευρωνικά δίκτυα[4].

1.3.1 Γιατί η Υπερ-παραμετροποίηση Βελτιώνει τη Γενίκευση;

Η εύρεση των λύσεων του μοντέλου βασίζεται στον αριθμό των παραμέτρων. Όταν το μοντέλο έχει λιγότερες παραμέτρους από ότι δεδομένα δεν υπάρχει λύση η οποία να προσαρμοστεί ακριβώς σε όλα τα δεδομένα. Για τον λόγο αυτό η αποτελεσματικότητα ενός τέτοιου μοντέλου κρίνεται από μεθόδους όπως την Μέθοδο Ελαχίστων Τετραγώνων. Όταν το μοντέλο βρίσκεται στο Σημείο Παρεμβολής υπάρχει μία μοναδική λύση η οποία προσαρμόζεται ακριβώς σε όλα τα δεδομένα. Αυτός είναι ο λόγος για τον οποίο η διακύμανση μεγιστοποιείται. Όταν το μοντέλο Υπερ-παραμετροποιείται οι λύσεις γίνονται άπειρες. Η πληθώρα επιλογών είναι η αιτία της δεύτερης πτώσης του σφάλματος. Στην περίπτωση αυτή ως βέλτιστη λύση κρίνεται εκείνη η οποία έχει την μικρότερη νόρμα βαρών δηλαδή η λύση με το μικρότερο μέγεθος βαρών.

$$\|w\|_2 = \sqrt{\sum_{i=1}^{d} w_i^2} = \sqrt{w_1^2 + w_2^2 + \cdots + w_d^2} \tag{2}$$

Ο μαθηματικός τύπος (2) αποτελεί την Ευκλείδεια Νόρμα (L_2 norm), μια από τις πιο ευρέως χρησιμοποιημένες νόρμες. Η ιδανική λύση είναι εκείνη η οποία μας δίνει το μικρότερο $\|w\|_2$ η οποία παράλληλα λειτουργεί έμμεσα σαν κανονικοποίηση.

1.3.2 Ο Ρόλος του Χρόνου Εκπαίδευσης στην Διπλή Κάθοδο

Αναφέρθηκε ότι η πολυπλοκότητα ορίζεται ως ο αριθμός των παραμέτρων του μοντέλου σε σχέση με τον αριθμό των δεδομένων και πως μέσω Υπερ-παραμετροποίησης, το μοντέλο βιώνει μια δεύτερη πτώση του σφάλματος γενίκευσης. Ωστόσο, πολυπλοκότητα μπορεί να οριστεί και βάσει του χρόνου εκπαίδευσης ενός μοντέλου. Υπό αυτό το πρίσμα, αποδεικνύεται πως σε μοντέλα με αριθμό παραμέτρων κοντά στο όριο παρεμβολής, όταν υπάρχει αύξηση του χρόνου εκπαίδευσης, παρατηρείται και σε αυτά το φαινόμενο της Διπλής Καθόδου[4]. Έτσι επιτυγχάνεται και με αυτόν τον τρόπο βελτίωση του σφάλματος γενίκευσης.

1.3.3 Ο Ρόλος του Δείγματος Εκπαίδευσης στην Διπλή Κάθοδο

Καθώς η πολυπλοκότητα αποτελεί την σχέση μεταξύ παραμέτρων και δεδομένων, υπάρχει ενδιαφέρον στην διερεύνηση του ερωτήματος πως η ικανότητα γενίκευσης του μοντέλου επηρεάζεται από το μέγεθος του Δείγματος Εκπαίδευσης. Ορίζοντας έναν σταθερό αριθμό παραμέτρων d και αυξάνοντας το δείγμα n στην ουσία το Σφάλμα Γενίκευσης ακολουθεί την ανάποδη πορεία που ακολουθούσε στην μέθοδο της Υπερ-παραμετροποίησης. Έτσι ξεκινώντας από το σημείο όπου $d > n$, καθώς αυξάνεται το δείγμα το σφάλμα είναι σχετικά χαμηλό καθώς το μοντέλο είναι ακόμα Υπερ-παραμετροποιημένο. Καθώς όμως το μοντέλο πλησιάζει το Όριο Παρεμβολής όπου $d = n$ το σφάλμα αρχίζει να αυξάνεται μέχρι τα δεδομένα να γίνουν περισσότερα από τις παραμέτρους ($n > d$) και το σφάλμα να αρχίσει να μειώνεται ξανά. Σε αυτό το σημείο το μοντέλο είναι στην Υπο-παραμετροποιημένη περιοχή όπου κυριαρχεί η Κλασική προσέγγιση πως όσα περισσότερα δεδομένα έχει το μοντέλο τόσο καλύτερα. Συμπεραίνοντας καταλαβαίνουμε πως οι περιοχές βελτίωσης του Σφάλματος Γενίκευσης βρίσκονται περιμετρικά του Ορίου Παρεμβολής και πως ανεξαρτήτως τρόπου όταν το μοντέλο πλησιάζει σε αυτό, το Σφάλμα αυξάνεται.

2 Παρουσίαση του Φαινομένου της Διπλής Καθόδου

2.1 Δεδομένα

Για την παρουσίαση του φαινομένου χρησιμοποιήθηκαν προσομοιωμένα δεδομένα καθώς και το σετ πραγματικών δεδομένων Heart Disease από το Kaggle. Το σετ αποτελείται από 270 παρατηρήσεις με 14 μεταβλητές, μια εκ των οποίων είναι η απαντητική μεταβλητή Heart.Disease. Οι μεταβλητές κανονικοποιήθηκαν αφού πρώτα μετατράπηκαν στον κατάλληλο τύπο. Στόχος είναι να βρεθεί η παρουσία καρδιακής νόσου.

2.2 Μεθοδολογία

Για τη προσέγγιση του φαινομένου επιλέχθηκε η μέθοδος της Υπερ-παραμετροποίησης σε ένα δίκτυο νευρώνων με τυχαία βάρη (Random Fourier Features). Το μοντέλο αυτό ουσιαστικά προσομοιώνει ένα νευρωνικό δίκτυο ενός κρυφού επιπέδου. Βασικός λόγος για την συγκεκριμένη επιλογή αποτελεί η γρήγορη υπολογιστική ταχύτητα καθώς και η ευκολία στον έλεγχο του αριθμού των παραμέτρων d η οποία μας δίνει την δυνατότητα του προσδιορισμού του Σημείου Παρεμβολής. Για την υλοποίηση έγινε χρήση της γλώσσας R καθώς και των πακέτων MASS για βοήθεια με τους υπολογισμούς και ggplot2 για την οπτικοποίηση.

2.2.1 Προσομοιωμένα Δεδομένα

Για τα προσομοιωμένα δεδομένα αρχικά προσομοιώσαμε το σύνολο εκπαίδευσης μεγέθους $n = 200$ και το σύνολο ελέγχου και ορίσαμε τον αριθμό των παραμέτρων. Τα δεδομένα είναι γραμμικώς εξαρτημένα με την προσθήκη θορύβου για τυχαιότητα. Στην συνέχεια ορίστηκε η συνάρτηση μετασχηματισμού των δεδομένων σε νευρώνες μέσω της μεθόδου Random Fourier Features καθώς και οι αντίστοιχες παράμετροι της συνάρτησης (τυχαία βάρη και μετατοπίσεις). Ύστερα περάσαμε τα δυο σύνολα από την συνάρτηση μετατροπής σε νευρώνες και με την χρήση της ψευδο-αντιστρόφου μήτρας Moore-Penrose κάναμε προβλέψεις για τα δυο σύνολα εκπαίδευσης και ελέγχου προκειμένου να προσδιορίσουμε το Σημείο Παρεμβολής και να αξιολογήσουμε την ικανότητα γενίκευσης του μοντέλου αντίστοιχα. Στην συνέχεια υπολογίστηκε το Μέσο Τετραγωνικό Σφάλμα (MSE) των προβλέψεων στα δύο σύνολα. Η διαδικασία αυτή υλοποιήθηκε για διάφορες τιμές παραμέτρων d.

2.2.2 Πραγματικά Δεδομένα (Heart Disease)

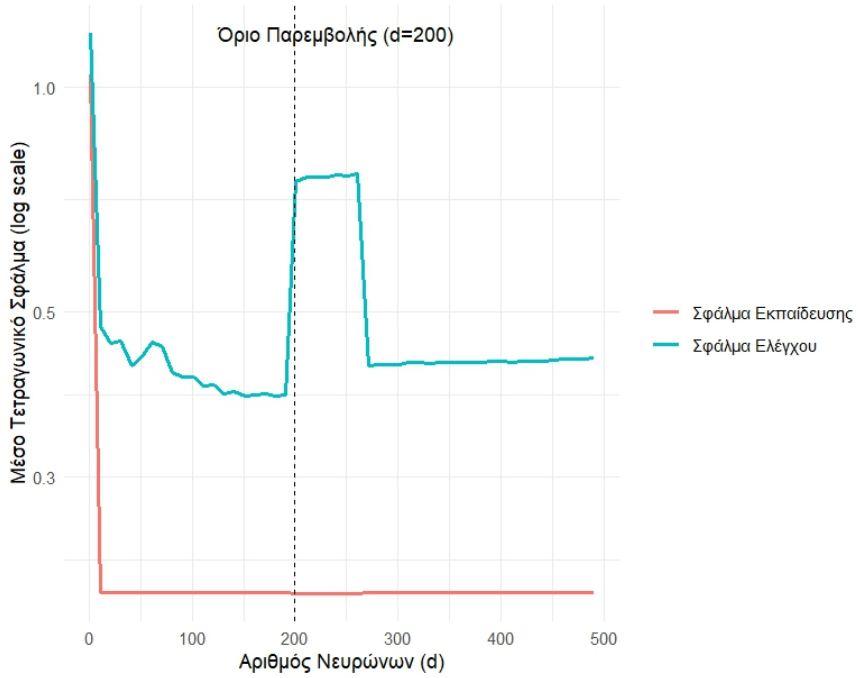
Η διαδικασία στα πραγματικά δεδομένα είναι δομικά όμοια με αυτή των προσομοιωμένων δεδομένων εκτός συγκεκριμένων σημείων λόγω της φύσης των δεδομένων. Το δείγμα χωρίστηκε στα $n_1 = 150$ δεδομένα για το σύνολο εκπαίδευσης και $n_2 = 120$ για το σύνολο ελέγχου. Ενώ προηγουμένως τα βάρη ήταν διάνυσμα καθώς τα δεδομένα ήταν μονοδιάστατα, λόγω της πολυδιάστατης φύσης των πραγματικών δεδομένων τα βάρη σε αυτή την περίπτωση παίρνουν την μορφή πίνακα.

Η χρήση της μήτρας Moore-Penrose είναι αναγκαία καθώς επιτρέπει την επίλυση μη τετραγωνικών συστημάτων και επιλέγει την λύση με την ελάχιστη νόρμα βαρών.

3 Αποτελέσματα

Ύστερα από ανάλυση των δεδομένων, παρουσιάζονται τα παρακάτω διαγράμματα για την επιβεβαίωση καθώς και οπτικοποίηση του φαινομένου. Όπως αναφέρθηκε προηγουμένως η ικανότητα γενίκευσης αξιολογείται από το Σφάλμα Γενίκευσης του μοντέλου. Εφόσον η ικανότητα αυτή εκτιμάται εμπειρικά στο σύνολο ελέγχου, στο εξής θα χρησιμοποιούμε τον όρο Σφάλμα Ελέγχου (test error) έναντι του Σφάλματος Γενίκευσης. Στην ανάλυση ενός διαγράμματος απεικόνισης του φαινομένου της Διπλής Καθόδου υπάρχουν τρία σημεία στα οποία απαιτείται έμφαση: πριν το Όριο Παρεμβολής, στο σημείο του Ορίου Παρεμβολής και ύστερα από αυτό.

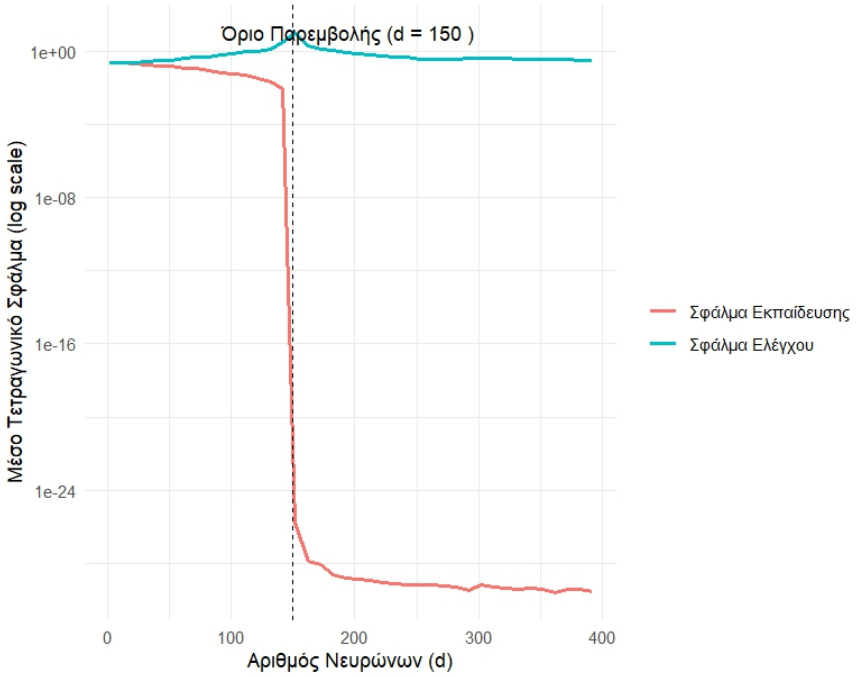
3.1 Προσομοιωμένα Δεδομένα



Σχήμα 1: Διάγραμμα Προσομοιωμένων Δεδομένων

Παρατηρώντας το διάγραμμα μπορούμε να δούμε το Σφάλμα Ελέγχου να μειώνεται καθώς αυξάνονται οι παράμετροι. Το σφάλμα φτάνει σε ένα τοπικό ελάχιστο μέχρι να αρχίσει ξανά να αυξάνεται καθώς ο αριθμός των παραμέτρων d πλησιάζει το μέγεθος του δείγματος εκπαίδευσης $n = 200$. Καθώς ο αριθμός των παραμέτρων d πλησιάζει το n παρατηρείται ραγδαία αύξηση του σφάλματος καθώς το μοντέλο σε αυτό το σημείο έχει γίνει ιδιόμορφο και επιτυγχάνει τέλεια παρεμβολή (interpolation) σε όλα τα δεδομένα εκπαίδευσης. Όταν ο αριθμός των παραμέτρων υπερβαίνει το Όριο Παρεμβολής το μοντέλο γίνεται Υπερ-παραμετροποιημένο όπου και παρατηρείται η δεύτερη πτώση του Σφάλματος Ελέγχου.

3.2 Πραγματικά Δεδομένα (Heart Disease)



Σχήμα 2: Διάγραμμα Πραγματικών Δεδομένων

Στο διάγραμμα των πραγματικών δεδομένων παρατηρούμε παρόμοια συμπεριφορά των σφαλμάτων με εκείνη των προσομοιωμένων δεδομένων. Εδώ το μέγεθος δείγματος εκπαίδευσης είχε οριστεί $n = 150$. Καθώς ο αριθμός των παραμέτρων προσεγγίζει το όριο παρεμβολής το Σφάλμα Ελέγχου αυξάνεται. Στη συγκεκριμένη περίπτωση όμως παρατηρείται και η πτώση του Σφάλματος Εκπαίδευσης όσο το μοντέλο πλησιάζει το Όριο Παρεμβολής. Στο Όριο Παρεμβολής το Σφάλμα Ελέγχου φτάνει στο μέγιστο ενώ το Σφάλμα Εκπαίδευσης πρακτικά μηδενίζεται, φαινόμενο που συνάδει με την θεωρία. Ύστερα με περαιτέρω αύξηση των παραμέτρων στην Υπερ-παραμετροποιημένη περιοχή παρατηρείται η αναμενόμενη μείωση του Σφάλματος Ελέγχου.

3.3 Διαφορές Μεταξύ των Διαγραμμάτων

Συγκρίνοντας τα δύο διαγράμματα μεταξύ τους εντοπίζονται ορισμένες διαφορές στην συμπεριφορά των δύο σφαλμάτων οι οποίες αποκλίνουν από την θεωρία.

Η πρώτη διαφορά παρατηρείται στο Σφάλμα Εκπαίδευσης καθώς ο μηδενισμός του επιτυγχάνεται σε δύο διαφορετικά σημεία ανά διάγραμμα. Στα προσομοιωμένα δεδομένα το Σφάλμα Εκπαίδευσης μειώνεται κοντά στην αρχή του διαγράμματος ενώ στα πραγματικά δεδομένα ο μηδενισμός παρατηρείται στο Όριο Παρεμβολής. Η δεύτερη διαφορά παρατηρείται στο Σφάλμα Ελέγχου όπου σε αντίθεση με τα προσομοιωμένα δεδομένα, στα πραγματικά δεδομένα το σφάλμα δεν λαμβάνει την μορφή καμπύλης σχήματος U αλλά αντιθέτως φαίνεται πως αυξάνεται από την αρχή. Τέλος διαφορές εντοπίζονται και στην οξύτητα των κορυφών του Σφάλματος Ελέγχου.

Η αιτία για τον πρόωρο μηδενισμό του Σφάλματος Εκπαίδευσης μπορεί να αποδοθεί στην φύση των δεδομένων που χρησιμοποιήθηκαν. Καθώς τα δεδομένα προήλθαν από μια συγκεκριμένη σχέση ενδέχεται να υπάρχει υψηλή γραμμική εξάρτηση μεταξύ τους. Λόγω αυτού το μοντέλο πιθανώς βρήκε τον κατάλληλο συνδυασμό βαρών που μηδενίζει το σφάλμα πριν το σημείο παρεμβολής. Η χρήση της ψευδο-αντιστρόφου μήτρας Moore-Penrose ενισχύει αυτή την υπόθεση.

Η διαφορά στην συμπεριφορά του Σφάλματος Ελέγχου μπορεί επίσης να αποδοθεί στην φύση των δεδομένων που χρησιμοποιήθηκαν καθώς τα πραγματικά δεδομένα κρύβουν εγγενή θόρυβο, πιο πολύπλοκο από αυτόν που μπορούμε να προσομοιώσουμε. Λόγω αυτής της πολυπλοκότητας το μοντέλο απαιτεί τις παραπάνω παραμέτρους προκειμένου να εξηγήσει καλά τα δεδομένα μας. Ακόμη δεν μπορεί να παραμεληθεί το ενδεχόμενο χρήσης μη-κατάλληλου μοντέλου για την περιγραφή των δεδομένων. Βάσει αυτής της λογικής το μοντέλο θα προσπαθούσε στην αρχή να προσαρμοστεί σε δεδομένα τα οποία ήταν εκτός των δυνατοτήτων του έως ότου προστεθούν αρκετοί παράμετροι. Όσον αφορά τις κορυφές του Σφάλματος Ελέγχου στα δύο διαγράμματα, οι διαφορές οφείλονται στην συνέργεια της κανονικοποίησης (scaling) και της έμμεσης κανονικοποίησης μέσω της μήτρας Moore-Penrose στα πραγματικά δεδομένα με το αποτέλεσμα να οδηγεί σε μια πιο ομαλή κορυφή.

4 Συμπεράσματα

Ο στόχος της παρούσας αναφοράς ήταν η ανάδειξη του φαινομένου της διπλής καθόδου. Με τη χρήση προσομοιωμένων καθώς και πραγματικών δεδομένων, ελέγχθηκε πώς η πολυπλοκότητα επηρεάζει την ικανότητα γενίκευσης ενός μοντέλου. Τα αποτελέσματα επιβεβαιώνουν αφενός τις ανησυχίες της κλασικής προσέγγισης για την Υπερ-προσαρμογή που οδηγεί σε αδυναμία γενίκευσης, αφετέρου την εμφάνιση της δεύτερης καθόδου του Σφάλματος Γενίκευσης μέσω της Υπερ-παραμετροποίησης. Η επιβεβαίωση των συμπερασμάτων τόσο στα προσομοιωμένα όσο και στα πραγματικά δεδομένα, αποτελεί απόδειξη της καθολικότητας του φαινομένου της Διπλής Καθόδου.

Η συγκεκριμένη ανακάλυψη ανοίγει τον δρόμο για την δημιουργία και υλοποίηση νέων μεθόδων καθώς καταρρίπτεται η κλασική αντίληψη της απλότητας ως μοναδικής λύσης. Έτσι μέσω του φαινομένου της Διπλής Καθόδου εξηγείται γιατί η Υπερ-παραμετροποίηση δεν είναι ελάττωμα αλλά πλεονέκτημα στη σύγχρονη Μηχανική Μάθηση και μέσω αυτού δίνεται η δυνατότητα ανάπτυξης πολύπλοκων συστημάτων, όπως τα μοντέλα τύπου GPT, τα οποία ξεκλειδώνουν νέες ευκαιρίες και δυνατότητες που προηγουμένως φάνταζαν ακατόρθωτες.

References

[1] Mikhail Belkin, Daniel Hsu, Siyuan Ma, and Soumik Mandal. Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proceedings of the National Academy of Sciences*, 116(32):15849–15854, 2019.

[2] Issam El Naqa and Martin J Murphy. What is machine learning? In *Machine learning in radiation oncology: theory and applications*, pages 3–11. Springer, 2015.

[3] Trevor Hastie, Robert Tibshirani, Jerome Friedman, and James Franklin. The elements of statistical learning: data mining, inference and prediction. *The Mathematical Intelligencer*, 27(2):83–85, 2005.

[4] Preetum Nakkiran, Gal Kaplun, Yamini Bansal, Tristan Yang, Boaz Barak, and Ilya Sutskever. Deep double descent: Where bigger models and more data hurt. *Journal of Statistical Mechanics: Theory and Experiment*, 2021(12):124003, 2021.